

Univerzitet u Beogradu

Matematički fakultet

Zapisnik o radu

Analiza proteinskih sekvenci hantavirusa
primenom metoda klasterizacije

Student: Vladimir Mandić

Beograd, 2026.

Sadržaj

1	Uvod i cilj rada	3
2	Priprema i obrada ulaznih podataka	3
2.1	Ulazni FASTA podaci	4
2.2	Uklanjanje tandemskih ponavljanja	4
3	Filtriranje i kontrola kvaliteta sekvenci	5
3.1	Provera anomalnih sekvenci	5
3.2	Konačni kriterijumi filtriranja	5
3.3	Veličina konačnih skupova	6
3.4	Distribucija dužina sekvenci	6
3.5	Kontrola karakteristika nakon filtriranja	6
4	Konstrukcija karakteristika	7
4.1	Karakteristike tandemskih ponavljanja	7
4.2	Dužina sekvence	7
4.3	Konačna tabela promenljivih	8
4.4	Provera promenljivih	8
5	Standardizacija i PCA analiza	8
5.1	Redukcija dimenzionalnosti	9
5.2	Objašnjena varijansa	9
5.3	PCA projekcija	9
6	Klasterizacija	10
6.1	K-Means	10
6.2	Agglomerative Clustering	10
6.3	Gaussian Mixture Model	10
6.4	DBSCAN	11
6.5	Spectral Clustering	11
6.6	Poređenje metoda	12
7	Evaluacija klasterizacije	12
7.1	Silhouette score	12
7.2	Adjusted Rand Index	13
7.3	Normalized Mutual Information	13
7.4	Značaj korišćenja više metrika	13
7.5	Rezultati evaluacije	14
8	Analiza rezultata	14
8.1	GPC / all	14
8.2	GPC / complete	15
8.3	N / all	16
8.4	N / complete	16
8.5	Opšti pregled rezultata	17
8.6	Zbirni pregled rezultata	17
9	Vizuelizacija rezultata	17

9.1	GPC / all	18
9.2	GPC / complete	18
9.3	N / all	19
9.4	N / complete	20
9.5	Poređenje vizuelizacija	21
9.6	Zaključak vizuelne analize	21
10	Zaključak	22

1 Uvod i cilj rada

Predmet rada je analiza proteinskih sekvenci hantavirusa primenom metoda nenadgledanog mašinskog učenja, sa posebnim fokusom na klasterizaciju sekvenci na osnovu njihovih karakteristika.

Analiza je sprovedena nad dva tipa proteina hantavirusa:

- GPC (glikoproteinski prekursor),
- N (nukleokapsidni protein).

Za svaki tip proteina razmatrane su dve grupe sekvenci:

- *all* – sve sekvence koje zadovoljavaju definisane kriterijume filtriranja,
- *complete* – sekvence označene kao kompletne.

Cilj rada je da se ispita da li se sekvence različitih vrsta hantavirusa mogu prirodno grupisati na osnovu numeričkih karakteristika izvedenih iz njihovih proteinskih sekvenci. U tu svrhu formiran je skup karakteristika, izvršena je redukcija dimenzionalnosti primenom metode PCA, a zatim je primenjeno više metoda klasterizacije.

Razmatrane su sledeće metode klasterizacije:

- K-Means,
- Agglomerative Clustering,
- Gaussian Mixture Model,
- DBSCAN,
- Spectral Clustering.

Dobijeni rezultati su međusobno upoređeni korišćenjem metrika Silhouette score, Adjusted Rand Index (ARI) i Normalized Mutual Information (NMI). Pored numeričke evaluacije, rezultati su analizirani i vizuelno kroz PCA projekcije.

Poseban deo analize odnosi se na proveru kvaliteta ulaznih podataka i identifikaciju anomalnih sekvenci koje mogu značajno uticati na rezultate klasterizacije.

2 Priprema i obrada ulaznih podataka

Početni skup podataka sastoji se od proteinskih sekvenci hantavirusa zapisanih u FASTA formatu. Sekvence su organizovane prema vrsti hantavirusa, tipu proteina i stepenu kompletnosti sekvence.

U analizi su obuhvaćene četiri grupe odnosno vrste hantavirusa:

- *dobravaense*,
- *hantanense*,
- *puumalaense*,
- *sinnombreense*.

Za svaku vrstu posmatrana su dva proteina:

- GPC,
- N.

Takođe su odvojeno posmatrane sekvence koje pripadaju skupu *all* i sekvence označene kao *complete*. Na taj način formirane su četiri kombinacije podataka za svaki tip proteina:

- GPC / *all*,
- GPC / *complete*,
- N / *all*,
- N / *complete*.

2.1 Ulazni FASTA podaci

Za svaku kombinaciju vrste, proteina i kompletnosti korišćen je odgovarajući FASTA fajl. Ukupno je obrađeno 16 ulaznih fajlova, koji odgovaraju svim kombinacijama četiri vrste, dva proteina i dva nivoa kompletnosti.

Pre nastavka analize izvršena je kontrola uspešnosti obrade svih ulaznih fajlova. Za svaki fajl provereno je da li je izvršavanje alata završeno uspešno i da li je očekivani izlazni fajl kreiran.

Za sve obrađene fajlove dobijen je povratni kod:

returncode = 0,

a izlazni fajlovi su uspešno generisani.

2.2 Uklanjanje tandemskih ponavljanja

Nad proteinskim sekvencama primenjen je alat *RepeatsPlus* radi identifikacije i obrade tandemskih ponavljanja u sekvencama.

Rezultati obrade čuvani su u zasebnim izlaznim fajlovima, koji su zatim korišćeni u nastavku pipeline-a za formiranje karakteristika sekvenci.

Za svaku sekvencu izračunate su karakteristike koje opisuju prisustvo ponavljanja različitih dužina. U daljoj analizi korišćene su karakteristike za ponavljanja dužine 3, 4, 5, 6 i 8 aminokiselina.

Pored apsolutnog broja odnosno dužine detektovanih ponavljanja, uvedene su i normalizovane karakteristike. Na ovaj način se učestalost ponavljanja može posmatrati u odnosu na ukupnu dužinu proteinske sekvence, čime se smanjuje direktan uticaj različite dužine proteina na vrednosti karakteristika.

3 Filtriranje i kontrola kvaliteta sekvenci

Nakon početne obrade izvršena je kontrola dužine proteinskih sekvenci. Cilj ovog koraka bio je da se iz dalje analize uklone sekvence koje po svojoj dužini značajno odstupaju od očekivane dužine odgovarajućeg proteina.

Za početno filtriranje korišćeni su sledeći kriterijumi:

Tabela 1: Početni kriterijumi za filtriranje sekvenci

Protein	Minimalna dužina
GPC	1000 AK
N	400 AK

Kriterijumi su izabrani na osnovu očekivanih dužina posmatranih proteina. GPC protein je znatno duži od N proteina, zbog čega je za njega korišćen viši prag.

3.1 Provera anomalnih sekvenci

Tokom kontrole rezultata filtriranja uočeno je da se u skupu N proteina vrste *sinnombre-ense* nalaze dve sekvence koje značajno odstupaju od očekivane dužine N proteina.

Radi se o sekvencama:

- AFV71290.1,
- AFV71289.1.

Obe sekvence imaju dužinu od 1140 aminokiselina, dok je očekivana dužina N proteina približno 400–500 aminokiselina. Istovremeno, njihova anotacija ih označava kao:

nucleocapsid protein [Orthohantavirus sinnombreense]

Dakle, prema anotaciji pripadaju N proteinu, ali se njihova dužina značajno razlikuje od tipične dužine N proteinskih sekvenci.

Ovaj slučaj pokazuje da sama anotacija sekvence nije dovoljna za kontrolu kvaliteta ulaznih podataka. Zbog toga je uvedena dodatna kontrola zasnovana na dužini sekvence.

3.2 Konačni kriterijumi filtriranja

Na osnovu uočene anomalije uvedena je i gornja granica za dužinu N proteina. Konačni kriterijumi korišćeni u analizi prikazani su u tabeli 2.

Tabela 2: Konačni kriterijumi za filtriranje sekvenci

Protein	Minimalna dužina	Maksimalna dužina
GPC	1000 AK	–
N	400 AK	500 AK

Tako sekvence N proteina kraće od 400 ili duže od 500 aminokiselina nisu uključene u konačan skup podataka.

Uvođenjem gornje granice od 500 aminokiselina uklonjene su prethodno navedene anomalne sekvence dužine 1140 aminokiselina. Time je obezbeđeno da se u daljoj analizi koriste sekvence koje su u skladu sa očekivanim karakteristikama odgovarajućeg proteina.

3.3 Veličina konačnih skupova

Nakon filtriranja dobijene su sledeće veličine skupova koji su korišćeni u završnim eksperimentima klasterizacije:


Tabela 3: Broj sekvenci u konačnim skupovima za klasterizaciju

Skup	Broj sekvenci	Broj vrsta
GPC / all	500	4
GPC / complete	121	4
N / all	1241	4
N / complete	170	4

Ove veličine odgovaraju skupovima nad kojima su sprovedeni završni eksperimenti. Posebno je uočljiva razlika između broja dostupnih sekvenci u *all* i *complete* skupovima, naročito kod N proteina.

3.4 Distribucija dužina sekvenci

Radi dodatne kontrole kvaliteta podataka analizirana je distribucija dužina proteinskih sekvenci. Ovaj prikaz je posebno važan za N protein, jer je tokom kontrole uočeno odstupanje sekvenci dužine 1140 aminokiselina.



Slika 1: Distribucija dužina proteinskih sekvenci pre konačnog filtriranja.

Distribucija pokazuje da se kod N proteina pojavljuju i sekvence dužine 1140 aminokiselina, koje su izrazito udaljene od većine sekvenci. Detaljnom proverom identifikovane su dve takve sekvence. Nakon primene konačnih kriterijuma filtriranja, ove sekvence nisu prisutne u skupovima korišćenim za završnu klasterizaciju.

3.5 Kontrola karakteristika nakon filtriranja

Nakon filtriranja provereno je da se u konačnim skupovima nalaze samo sekvence koje zadovoljavaju definisane kriterijume. Takođe je provereno da nijedan od podskupova koji se dalje koristi za klasterizaciju nije prazan.

Dobijeni filtrirani podaci predstavljaju osnovu za formiranje numeričke reprezentacije sekvenci i primenu metoda nenadgledanog mašinskog učenja.

4 Konstrukcija karakteristika

Nakon filtriranja sekvenci formirana je numerička reprezentacija svake proteinske sekvence. Cilj ovog koraka je da se sekvence, koje su inicijalno predstavljene kao nizovi aminokiselina, predstavje skupom numeričkih karakteristika pogodnim za primenu metoda klasterizacije.

Za svaku sekvencu beležene su osnovne informacije o poreklu sekvence, kao što su vrsta, tip proteina i kompletnost, dok su za potrebe klasterizacije korišćene karakteristike izvedene iz detektovanih tandemskih ponavljanja i dužine sekvence.

4.1 Karakteristike tandemskih ponavljanja

Na osnovu rezultata prethodne obrade formirane su karakteristike koje opisuju prisustvo ponavljanja različitih dužina. Korišćene su sledeće karakteristike:

- `repeats_len_3`,
- `repeats_len_4`,
- `repeats_len_5`,
- `repeats_len_6`,
- `repeats_len_8`.

Naziv karakteristike označava dužinu ponavljanja koju karakteristika opisuje. Na primer, `repeats_len_3` predstavlja informaciju o ponavljanjima dužine 3 aminokiseline, dok `repeats_len_8` opisuje ponavljanja dužine 8 aminokiselina.

Pored apsolutnih vrednosti, za svaku od navedenih karakteristika izračunata je i normalizovana vrednost:

$$x_{\text{norm}} = \frac{x}{L},$$

gde je x odgovarajuća karakteristika ponavljanja, a L dužina proteinske sekvence.

Na ovaj način dobija se relativna učestalost ponavljanja u odnosu na ukupnu dužinu sekvence.

4.2 Dužina sekvence

Pored karakteristika tandemskih ponavljanja, za svaku sekvencu zabeležena je i njena ukupna dužina:

$$L = \text{seq_length}.$$

Dužina sekvence predstavlja osnovnu karakteristiku proteinskog zapisa i koristi se u analizi zajedno sa karakteristikama ponavljanja.

4.3 Konačna tabela promenljivih

Nakon obrade formirana je tabela koja objedinjuje informacije o sekvencama i njihove numeričke promenljive. Početna tabela sadržala je 2032 sekvence i 15 atributa.

Među atributima se nalaze kategoričke promenljive:

- `species`,
- `completeness`,
- `protein`,

kao i numeričke promenljive:

- `seq_length`,
- `repeats_len_3`,
- `repeats_len_4`,
- `repeats_len_5`,
- `repeats_len_6`,
- `repeats_len_8`,
- normalizovane promenljive odgovarajućih dužina ponavljanja.

Atributi `species`, `completeness` i `protein` koriste se za opisivanje i kasniju evaluaciju rezultata, dok numeričke promenljive predstavljaju osnovu za klasterizaciju.

4.4 Provera promenljivih

Pre primene algoritama izvršena je kontrola dobijenih promenljivih. Posebno je provereno prisustvo promenljivih sa veoma malom varijansom, kao i promenljivih koje su dominantno jednake nuli.

Uočeno je da promenljiva `repeats_len_6` u jednom od analiziranih skupova ima izrazito neuravnoteženu raspodelu, sa velikim brojem nultih vrednosti i veoma malim brojem sekvenci kod kojih je promenljiva različita od nule.

Ovakve promenljive mogu imati disproporcionalan uticaj nakon standardizacije i zbog toga je njihovo ponašanje uzeto u obzir prilikom interpretacije rezultata PCA analize i klasterizacije.

5 Standardizacija i PCA analiza

Pre primene algoritama klasterizacije izvršena je standardizacija numeričkih promenljivih. Ovaj korak je važan zato što promenljive mogu imati različite opsege vrednosti, pa bi promenljiva sa većim apsolutnim vrednostima mogla nesrazmerno uticati na izračunavanje rastojanja između sekvenci.

Za standardizaciju je korišćen standardni oblik:

$$z = \frac{x - \mu}{\sigma},$$

gde je x originalna vrednost promenljive, μ srednja vrednost promenljive, a σ njena standardna devijacija.

Nakon standardizacije svaka numerička promenljiva ima približno nultu srednju vrednost i jediničnu standardnu devijaciju.

5.1 Redukcija dimenzionalnosti

Nakon standardizacije primenjena je metoda Principal Component Analysis (PCA). PCA omogućava predstavljanje podataka u prostoru sa manjim brojem dimenzija uz očuvanje što većeg dela varijabilnosti početnog skupa.

U početnom prostoru karakteristike sekvenci predstavljene su većim brojem numeričkih dimenzija. PCA transformacijom dobijaju se nove ortogonalne komponente, pri čemu prva komponenta objašnjava najveći deo varijanse, druga najveći deo preostale varijanse itd.

Za potrebe vizuelizacije korišćene su prve dve glavne komponente:

$$PC_1, \quad PC_2.$$

Tako svaka sekvenca može da se predstavi jednom tačkom u dvodimenzionalnom prostoru koji određuju prve dve glavne komponente PCA analize.

5.2 Objašnjena varijansa

Pored same projekcije podataka, analiziran je i udeo varijanse koji objašnjavaju glavne komponente.

U analiziranom skupu prve tri glavne komponente zajedno objašnjavaju približno 97.1% ukupne varijanse. To pokazuje da se najveći deo informacija sadržanih u početnim karakteristikama može predstaviti sa veoma malim brojem komponenti.

Zbog toga je PCA pogodan za vizuelnu analizu strukture podataka i prikaz rezultata klasterizacije.

5.3 PCA projekcija

Za svaki od analiziranih podskupova formirana je PCA projekcija u ravni koju određuju prve dve glavne komponente.

Na ovim projekcijama prikazana je raspodela sekvenci prema njihovoj stvarnoj vrsti, a zatim su preko iste projekcije prikazani rezultati pojedinačnih algoritama klasterizacije.

Ovakav prikaz omogućava direktno poređenje strukture koju daju algoritmi klasterizacije sa stvarnom pripadnošću sekvenci vrstama.

PCA se u ovom radu koristi prvenstveno kao sredstvo za redukciju dimenzionalnosti i vizuelizaciju. Sama PCA transformacija ne određuje klastere, već algoritmi klasterizacije rade nad numeričkom reprezentacijom podataka.

6 Klasterizacija

Nakon standardizacije numeričkih promenljivih primenjene su različite metode klasterizacije. Cilj je bio da se ispita da li se proteinske sekvence mogu grupisati na osnovu svojih karakteristika i da se uporede rezultati različitih pristupa.

U analizi su korišćene sledeće metode:

- K-Means,
- Agglomerative Clustering,
- Gaussian Mixture Model,
- DBSCAN,
- Spectral Clustering.

Za većinu metoda korišćen je broj klastera $k = 4$, što odgovara broju vrsta koje se razlikuju u analiziranom skupu podataka. Na taj način omogućeno je poređenje dobijenih klastera sa stvarnom pripadnošću sekvenci vrstama.

6.1 K-Means

K-Means je metoda klasterizacije koja deli podatke u unapred zadat broj klastera. U ovom radu korišćena je vrednost

$$k = 4.$$

Algoritam iterativno dodeljuje svaku sekvencu najbližem centroidu, a zatim ažurira položaje centroida na osnovu trenutno dodeljenih sekvenci. Postupak se ponavlja dok se položaji centroida i pripadnost klasterima ne stabilizuju.

K-Means predstavlja osnovni referentni model za poređenje sa ostalim metodama.

6.2 Agglomerative Clustering

Agglomerative Clustering predstavlja hijerarhijski pristup klasterizaciji. Početno se svaka sekvenca posmatra kao zaseban klaster, nakon čega se najbliži klasteri postepeno spajaju.

U eksperimentu je korišćen broj od četiri konačna klastera:

$$k = 4.$$

Za razliku od K-Means metode, ovaj pristup ne predstavlja klastere pomoću centroida, već gradi hijerarhijsku strukturu spajanja podataka.

6.3 Gaussian Mixture Model

Gaussian Mixture Model (GMM) modeluje podatke kao kombinaciju više Gaussovih distribucija. Za svaki uzorak procenjuje se verovatnoća pripadnosti svakoj od komponenti modela.

U eksperimentu su korišćene četiri komponente:

$$k = 4.$$

Za razliku od K-Means metode, GMM omogućava probabilističku pripadnost sekvenci različitim grupama, što može biti korisno kada granice između grupa nisu jasno definisane.

6.4 DBSCAN

DBSCAN je metoda klasterizacije zasnovana na gustini podataka. Za razliku od prethodno navedenih metoda, DBSCAN ne zahteva da se broj klastera unapred zada.

Glavni parametri metode su:

- `eps` – maksimalno rastojanje za određivanje susedstva,
- `min_samples` – minimalan broj tačaka potreban za formiranje guste oblasti.

Zbog toga što broj klastera nije unapred poznat, ispitano je više vrednosti parametra `eps`. Razmatrane su vrednosti:

$$0.15, \quad 0.25, \quad 0.35, \quad 0.50.$$

Za svaku vrednost analiziran je broj pronađenih klastera i broj sekvenci koje su označene kao šum (*noise*).

Za odabir konačne konfiguracije posmatrani su kvalitet formiranih klastera, broj sekvenci označenih kao šum i očuvanje strukture podataka.

U jednom od analiziranih slučajeva za

$$\text{eps} = 0.35$$

dobijeno je 10 klastera i 19 sekvenci označenih kao šum. Ova konfiguracija je zadržana kao jedna od reprezentativnih DBSCAN konfiguracija za dalju evaluaciju.

6.5 Spectral Clustering

Spectral Clustering koristi reprezentaciju podataka preko grafa sličnosti i zatim vrši klasterizaciju u prostoru dobijenom spektralnom dekompozicijom.

U eksperimentu je korišćen broj od četiri klastera:

$$k = 4.$$

Tokom izvršavanja zabeleženo je upozorenje da graf nije potpuno povezan:

Graph is not fully connected, spectral embedding may not work as expected.

Ovo upozorenje je uzeto u obzir prilikom interpretacije rezultata Spectral Clustering metode, jer nepovezanost grafa može negativno uticati na kvalitet dobijenog spektralnog embedding-a i samim tim na konačnu klasterizaciju.

6.6 Poređenje metoda

Primena više različitih metoda omogućava poređenje klasterizacija koje se zasnivaju na različitim pretpostavkama.

K-Means i Gaussian Mixture koriste unapred definisan broj grupa, Agglomerative Clustering gradi hijerarhiju grupa, DBSCAN pronalazi grupe na osnovu gustine, dok Spectral Clustering koristi strukturu grafa sličnosti.

Na taj način možemo da vidimo da li uočena struktura podataka ostaje slična kroz različite metode ili zavisi od konkretnog algoritma.

7 Evaluacija klasterizacije

Nakon primene različitih metoda klasterizacije potrebno je proceniti kvalitet dobijenih grupa. U radu su korišćene tri metrike:

- Silhouette score,
- Adjusted Rand Index (ARI),
- Normalized Mutual Information (NMI).

Prve tri metrike omogućavaju različite poglede na kvalitet klasterizacije. Silhouette score procenjuje unutrašnju strukturu dobijenih klastera, dok ARI i NMI omogućavaju poređenje dobijene klasterizacije sa poznatom pripadnošću sekvenci vrstama.

7.1 Silhouette score

Silhouette score meri koliko je svaka tačka dobro smeštena u svoj klaster u odnosu na ostale klastere.

Za jednu tačku definišu se:

$$a(i)$$

– prosečno rastojanje tačke i od ostalih tačaka u istom klasteru,

i

$$b(i)$$

– najmanje prosečno rastojanje tačke i od tačaka nekog drugog klastera.

Silhouette vrednost se zatim računa kao:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}.$$

Vrednost Silhouette score-a kreće se u intervalu $[-1, 1]$.

Veće pozitivne vrednosti ukazuju na kompaktnije i bolje međusobno odvojene klastere. Vrednosti bliske nuli ukazuju na preklapanje klastera, dok negativne vrednosti mogu ukazivati na pogrešno dodeljene tačke.

7.2 Adjusted Rand Index

Adjusted Rand Index (ARI) koristi se za poređenje dobijene klasterizacije sa poznatim klasama.

U ovom radu poznate klase predstavljaju vrste hantavirusa. ARI uzima u obzir parove sekvenci i proverava koliko se njihova pripadnost istoj ili različitim grupama poklapa između stvarnih oznaka i rezultata klasterizacije.

ARI je korigovan za slučajno poklapanje. Vrednost:

$$ARI = 1$$

odgovara savršenom poklapanju klasterizacije sa poznatim klasama, dok vrednosti blizu nule ukazuju na rezultate koji nisu značajno bolji od slučajnog grupisanja. Moguće su i negativne vrednosti.

7.3 Normalized Mutual Information

Normalized Mutual Information (NMI) meri količinu zajedničke informacije između dobijenih klastera i poznatih klasa.

U ovom slučaju poredi se:

- pripadnost sekvence klasteru,
- stvarna vrsta sekvence.

NMI ima vrednosti između 0 i 1:

$$0 \leq NMI \leq 1.$$

Veća vrednost znači da klasteri bolje odgovaraju stvarnoj podeli na vrste.

7.4 Značaj korišćenja više metrika

Nije dovoljno posmatrati samo jednu metriku. Na primer, algoritam može formirati veoma kompaktne klastere i ostvariti visok Silhouette score, a da ti klasteri ne odgovaraju stvarnim biološkim vrstama.

Zbog toga se u radu istovremeno posmatraju Silhouette, ARI i NMI.

Silhouette omogućava procenu kvaliteta klastera bez oslanjanja na poznate klase, dok ARI i NMI koriste poznatu pripadnost vrsti kao referentnu informaciju.

Na ovaj način lakše se razlikuju:

- algoritmi koji formiraju geometrijski dobro razdvojene klastere,

- algoritmi čiji klasteri dobro odgovaraju stvarnim vrstama,
- algoritmi kod kojih se ova dva svojstva ne poklapaju.

7.5 Rezultati evaluacije

Za svaki kombinovani skup podataka i svaku primenjenu metodu sačuvane su sledeće informacije:

- broj sekvenci,
- tip proteina,
- kompletnost skupa,
- naziv algoritma,
- broj pronađenih klastera,
- Silhouette score,
- ARI,
- NMI.

Dobijeni rezultati objedinjeni su u završnu tabelu `final_results`. Ukupno je razmatrano 20 rezultata, koji odgovaraju kombinaciji četiri podskupa podataka i pet metoda klasterizacije.

U nastavku će rezultati biti prikazani tabelarno i analizirani pojedinačno za GPC i N proteine, kao i za *all* i *complete* skupove.

8 Analiza rezultata

Rezultati klasterizacije analizirani su odvojeno za GPC i N proteine, kao i za skupove *all* i *complete*. Na taj način moguće je ispitati kako tip proteina i izbor sekvenci utiču na strukturu dobijenih klastera.

Za svaku kombinaciju podataka poređeni su rezultati svih pet metoda klasterizacije prema broju pronađenih klastera, Silhouette score-u, ARI i NMI.

8.1 GPC / all

Skup GPC / all obuhvata sve GPC sekvence koje su zadovoljile definisane kriterijume filtriranja.

Za ovaj skup algoritmi K-Means, Agglomerative Clustering i Gaussian Mixture koriste četiri klastera, dok DBSCAN određuje broj klastera na osnovu gustine podataka.

Kod ovog skupa posebno je značajno poređenje Silhouette score-a sa ARI i NMI metrikama. Visok Silhouette score ne mora nužno značiti da klasteri odgovaraju stvarnim vrstama, zbog čega je potrebno istovremeno posmatrati sve tri metrike.

Rezultati za GPC / all skup prikazani su u tabeli 4.

Tabela 4: Rezultati klasterizacije za GPC / all skup

Metoda	Klasteri	Silhouette	ARI	NMI
K-Means	4	0.639345	0.610387	0.523117
Agglomerative	4	0.608288	0.536283	0.470777
Gaussian Mixture	4	0.601509	0.616584	0.578081
DBSCAN	12	0.763695	0.451234	0.570265
Spectral	4	-0.327983	0.010778	0.139854

DBSCAN ostvaruje najviši Silhouette score među analiziranim metodama, što ukazuje na veoma kompaktnu i međusobno razdvojenu strukturu pronađenih klastera. Međutim, broj pronađenih klastera je veći od četiri, a ARI je niži nego kod K-Means i Gaussian Mixture metode.

Gaussian Mixture ostvaruje najviši ARI u ovom skupu, dok K-Means takođe daje veoma dobro poklapanje sa stvarnim vrstama. To ukazuje da geometrijski najkvalitetnija podela prema Silhouette metrici nije istovremeno i podela koja najbolje odgovara poznatim vrstama.

Spectral Clustering daje znatno slabije rezultate. Ovo je u skladu sa prethodno pomenutim problemom nepovezanosti grafa koji je zabeležen tokom njegovog izvršavanja.

8.2 GPC / complete

Skup GPC / complete sastoji se samo od sekvenci koje su označene kao kompletne.

Ovde se može videti da li uklanjanje sekvenci koje nisu označene kao kompletne dovodi do jasnije strukture u prostoru karakteristika.

Za svaku od pet metoda izračunate su iste evaluacione metrike: Silhouette, ARI i NMI. Dobijeni rezultati biće prikazani u tabeli 5.

Tabela 5: Rezultati klasterizacije za GPC / complete skup

Metoda	Klasteri	Silhouette	ARI	NMI
K-Means	4	0.602830	0.580098	0.574768
Agglomerative	4	0.604330	0.530726	0.506511
Gaussian Mixture	4	0.602830	0.580098	0.574768
DBSCAN	10	0.692645	0.235858	0.485362
Spectral	4	0.292335	0.210910	0.248919

Za GPC / complete skup DBSCAN ponovo ostvaruje najviši Silhouette score, ali sa 10 pronađenih klastera i znatno nižim ARI. K-Means i Gaussian Mixture daju najbolje rezultate prema ARI i NMI među metodama koje formiraju četiri klastera.

U poređenju sa GPC / all skupom, ograničavanje na kompletne sekvence nije dovelo do poboljšanja ARI i NMI rezultata. Kod K-Means i Gaussian Mixture ARI opada sa približno 0.61 odnosno 0.62 na 0.58, dok DBSCAN pokazuje još izraženiji pad ARI.

8.3 N / all

N / all skup obuhvata N proteinske sekvence koje zadovoljavaju konačne kriterijume filtriranja.

Kod ovog skupa je bitno što su prethodnom kontrolom dužine uklonjene anomalne sekvence dužine 1140 aminokiselina. To je važno za tumačenje rezultata klasterizacije.

Kod ovog skupa možemo da vidimo koliko karakteristike tandemskih ponavljanja pomažu u razdvajanju različitih vrsta N proteina. Ovi rezultati se zato porede sa rezultatima za GPC protein.

Tabela 6: Rezultati klasterizacije za N / all skup

Metoda	Klasteri	Silhouette	ARI	NMI
K-Means	4	0.790923	0.655787	0.593458
Agglomerative	4	0.791220	0.658662	0.596660
Gaussian Mixture	4	0.772110	0.666213	0.605153
DBSCAN	19	0.910618	0.640534	0.636469
Spectral	4	0.013696	-0.012369	0.045165

Kod DBSCAN-a je posebno zanimljivo što može formirati drugačiji broj klastera od broja poznatih vrsta, kao i označiti pojedine sekvence kao šum. U ovom eksperimentu DBSCAN pronalazi čak 19 klastera. Taj broj ne predstavlja procenu da u skupu postoji 19 bioloških vrsta, već broj gustinskih grupa koje je algoritam pronašao u datoj reprezentaciji podataka.

N / all pokazuje znatno jasniju strukturu nego GPC skupovi. DBSCAN ostvaruje najviši Silhouette score (0.910618), dok Gaussian Mixture ostvaruje najviši ARI (0.666213). DBSCAN ima najviši NMI (0.636469). I ovde se vidi da geometrijska kompaktnost klastera nije potpuno isto što i slaganje sa poznatim vrstama.

8.4 N / complete

Poslednji analizirani skup čine kompletne N proteinske sekvence.

Ovde možemo direktno da uporedimo rezultate sa N / all skupom i vidimo kakav je uticaj kompletnosti sekvenci na rezultate klasterizacije.

Tabela 7: Rezultati klasterizacije za N / complete skup

Metoda	Klasteri	Silhouette	ARI	NMI
K-Means	4	0.849212	0.540386	0.491577
Agglomerative	4	0.846483	0.540877	0.504851
Gaussian Mixture	4	0.839604	0.552986	0.499793
DBSCAN	7	0.880627	0.751638	0.691340
Spectral	4	0.777396	0.717654	0.649313

Poređenjem N / all i N / complete skupova uočava se značajna promena rezultata. Kod N / complete skupa DBSCAN ostvaruje $ARI = 0.751638$ i $NMI = 0.691340$, što su najbolje

vrednosti ARI i NMI među svim analiziranim konfiguracijama. Istovremeno, broj klastera koji DBSCAN pronalazi smanjuje se sa 19 na 7.

Ograničavanje na kompletne N sekvence zato daje bolje poklapanje klastera sa poznatim vrstama, iako je broj sekvenci u skupu znatno manji.

8.5 Opšti pregled rezultata

Rezultati pokazuju da različite metode klasterizacije mogu dati različite zaključke o strukturi istog skupa podataka.

Silhouette score prvenstveno opisuje unutrašnju geometrijsku strukturu klastera, dok ARI i NMI mere njihovu saglasnost sa poznatom podelom na vrste. Zbog toga se izbor najbolje metode ne može zasnivati samo na jednoj metrici.

Posebno je korisno posmatrati situacije u kojima jedna metoda ima visok Silhouette score, ali niže ARI i NMI vrednosti. Takav rezultat ukazuje da je algoritam pronašao kompaktnu strukturu, ali da ona ne odgovara nužno biološkoj podeli na vrste.

Nasuprot tome, visoke vrednosti ARI i NMI ukazuju da dobijeni klasteri bolje prate stvarnu pripadnost sekvenci vrstama.

8.6 Zbirni pregled rezultata

Najbolje vrednosti po pojedinačnim metrikama prikazane su u tabeli 8. Ovaj pregled ne označava jednu univerzalno najbolju metodu, već pokazuje koja metoda je bila najbolja prema konkretnoj metrici u svakom podskupu.

Tabela 8: Najbolje metode prema pojedinačnim metrikama

Skup	Najbolji Silhouette	Najbolji ARI	Najbolji NMI
GPC / all	DBSCAN	Gaussian Mixture	Gaussian Mixture
GPC / complete	DBSCAN	K-Means / GMM	K-Means / GMM
N / all	DBSCAN	Gaussian Mixture	DBSCAN
N / complete	DBSCAN	DBSCAN	DBSCAN

Iz zbirnog pregleda vidi se da DBSCAN gotovo sistematski ostvaruje najviši Silhouette score. Međutim, samo u N / complete skupu istovremeno ostvaruje i najbolji ARI i NMI. Kod GPC skupova najbolje poklapanje sa poznatim vrstama daju Gaussian Mixture odnosno K-Means/GMM, dok N / complete predstavlja najuspešniju konfiguraciju prema ARI i NMI.

9 Vizuelizacija rezultata


Radi lakšeg tumačenja rezultata klasterizacije, dobijeni klasteri su vizuelno prikazani u dvodimenzionalnom prostoru glavnih komponenti dobijenih PCA analizom.

Za svaki analizirani skup prikazana je ista PCA projekcija, pri čemu su zasebno prikazani stvarna pripadnost sekvence vrsti i rezultati pojedinačnih algoritama klasterizacije: K-Means, Agglomerative Clustering, Gaussian Mixture, DBSCAN i Spectral Clustering.

Ovako možemo direktno da uporedimo stvarnu distribuciju sekvenci sa grupama koje su pronašli algoritmi klasterizacije.

9.1 GPC / all

Na slici 2 prikazana je PCA projekcija sekvenci GPC / all skupa. Prvi grafikon prikazuje stvarnu pripadnost sekvenci vrstama, dok ostali grafikoni prikazuju rezultate pojedinačnih algoritama.




Slika 2: PCA projekcija i rezultati klasterizacije za GPC / all skup.

Kod GPC / all skupa većina metoda formira četiri klastera, što odgovara broju poznatih vrsta. DBSCAN predstavlja izuzetak, jer formira veći broj klastera na osnovu lokalne gustine podataka. Vizuelno se može uočiti da su pojedine grupe sekvenci relativno dobro razdvojene, dok kod drugih dolazi do preklapanja.

9.2 GPC / complete

Rezultati za GPC / complete skup prikazani su na slici 3. Za razliku od GPC / all skupa, ovde se analiza vrši samo nad kompletnim sekvencama.




Slika 3: PCA projekcija i rezultati klasterizacije za GPC / complete skup.

Ograničavanje skupa na kompletne sekvence dovodi do manjeg broja analiziranih primera, ali istovremeno uklanja sekvence nepotpune dužine. Poređenjem sa GPC / all skupom može se proceniti da li potpunost sekvence značajno utiče na strukturu klastera.

9.3 N / all

Na slici 4 prikazani su rezultati za N / all skup. Ovaj skup sadrži znatno veći broj sekvenci u odnosu na GPC skup, zbog čega je struktura podataka izraženija u PCA projekciji.




Slika 4: PCA projekcija i rezultati klasterizacije za N / all skup.

Na PCA projekciji se uočavaju jasno izdvojene grupe sekvenci, ali i pojedinačne tačke koje značajno odstupaju od glavne strukture podataka. Posebno je značajno što je u prethodnoj fazi analize identificirano nekoliko anomalnih sekvenci dužine 1140 aminokiselina, koje su nakon dodatnog filtriranja uklonjene iz konačnog skupa.

Kod numeričkih rezultata DBSCAN za ovaj skup formira 19 klastera, što je znatno više od četiri poznate vrste. To pokazuje da DBSCAN, iako ostvaruje visoku Silhouette vrednost, ne reprodukuje nužno strukturu stvarnih taksonomskih grupa.

9.4 N / complete

Na slici 5 prikazani su rezultati za N / complete skup, koji obuhvata samo kompletne N proteinske sekvence.



Slika 5: PCA projekcija i rezultati klasterizacije za N / complete skup.

U odnosu na N / all skup, broj sekvenci je značajno manji, ali osnovna struktura podataka ostaje vidljiva. Poređenje rezultata pokazuje da uklanjanje nepotpunih sekvenci menja kvalitet klasterizacije, naročito kod DBSCAN i Spectral metoda.

9.5 Poređenje vizuelizacija

Vizuelizacije sva četiri skupa omogućavaju kvalitativno poređenje ponašanja algoritama klasterizacije. Kod GPC skupova grupe su uglavnom manje i kompaktnije, dok se kod N skupa uočava izraženija struktura i veća udaljenost pojedinih grupa u PCA prostoru.

Važno je napomenuti da PCA projekcija prikazuje samo prve dve glavne komponente. Zbog toga vizuelna blizina dve sekvence u dvodimenzionalnoj projekciji ne mora značiti da su one bliske u celokupnom prostoru karakteristika.

Zbog toga vizuelizacije predstavljaju dopunu numeričkoj evaluaciji. Konačna procena kvaliteta klasterizacije zasniva se na kombinaciji vizuelnog uvida i metrika Silhouette, ARI i NMI.

9.6 Zaključak vizuelne analize

Vizuelni prikazi potvrđuju da karakteristike zasnovane na tandemskim ponavljanjima sa drže informaciju koja omogućava razdvajanje dela sekvenci prema vrsti. Međutim, kvalitet tog razdvajanja zavisi od izabranog algoritma i skupa podataka.

Posebno se izdvaja DBSCAN, koji često ostvaruje visoke vrednosti Silhouette metrike, ali istovremeno formira veći broj klastera od broja poznatih vrsta. Zbog toga visoka vrednost Silhouette metrike sama po sebi nije dovoljna za zaključak da algoritam uspešno rekonstruiše stvarnu taksonomsku strukturu.

Nasuprot tome, ARI i NMI omogućavaju direktnije poređenje dobijenih klastera sa poznatim oznakama vrsta, pa ih je potrebno posmatrati zajedno sa Silhouette metrikom i PCA vizuelizacijama.

10 Zaključak

Analiza je pokazala da karakteristike izvedene iz tandemskih ponavljanja sadrže informaciju koja omogućava delimično razdvajanje različitih vrsta hantavirusa. Međutim, kvalitet razdvajanja zavisi od tipa proteina, kompletnosti sekvenci i izabranog algoritma klasterizacije.

Kod GPC proteina najbolju saglasnost sa poznatim vrstama uglavnom daju metode sa unapred zadatim brojem klastera, posebno Gaussian Mixture za GPC / all i K-Means odnosno Gaussian Mixture za GPC / complete. DBSCAN ima viši Silhouette score, ali zbog većeg broja pronađenih klastera ne daje najbolje poklapanje sa stvarnim vrstama.

Kod N proteina rezultati su izraženiji. N / all ima visoke vrednosti Silhouette, ARI i NMI kod više metoda, dok N / complete daje naročito dobre rezultate. DBSCAN za N / complete postiže $ARI = 0.751638$ i $NMI = 0.691340$, što predstavlja najbolje poklapanje sa poznatim vrstama među svim analiziranim konfiguracijama.

Važan deo rada bila je kontrola kvaliteta podataka. Identifikacija dve sekvence dužine 1140 aminokiselina pokazala je da oslanjanje samo na tekstualnu anotaciju može biti nedovoljno. Uvođenjem gornje granice za dužinu N proteina uklonjena je uočena anomalija i dobijeni su konzistentniji skupovi za završnu analizu.

Konačno, rezultati pokazuju da ne postoji jedna metrika koja je dovoljna za izbor metode. Silhouette meri geometrijsku kvalitetu klastera, dok ARI i NMI mere saglasnost sa poznatim biološkim klasama. Zbog toga je kombinacija numeričkih metrika, kontrole kvaliteta podataka i PCA vizuelizacije pogodnija za donošenje zaključaka o kvalitetu klasterizacije.